




Regresión Lineal

Aprendizaje Automático 1

Regresión Lineal



Recta de regresión

$$y = a x + b$$


Se desconocen a y b .

Regresión Lineal Múltiple

Plano de regresión

$$Y = aX_1 + bX_2 + c$$

Se desconocen a , b y c .





Regresión Lineal Múltiple

Figura n-dimensional de regresión

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i = \mathbf{x}_i^T \boldsymbol{\beta} + \varepsilon_i, \quad i = 1, \dots, n,$$

p ejes.

Se desconocen p+1 parámetros.

¿Qué significa "buscar la mejor recta"?


La idea es encontrar una **función de pérdida** para determinar qué es lo que queremos minimizar. O en otras palabras, cómo **medir** la **mejor** figura n-dimensional que se adapte a nuestros datos.

Por lo general:

OLS - Ordinary Least Squares - Mínimos cuadrados

Este método consiste en **minimizar la suma de los cuadrados de las diferencias entre y_{true} y y_{pred}**

Siendo y_{true} el valor real de Y, e y_{pred} el valor dado por la figura de regresión.





Mínimos cuadrados

La distancia entre y_{true_i} e y_{pred_i} se puede medir como la resta entre ellos

$$d = y_{\text{true}_i} - y_{\text{pred}_i}$$

Puesto que esta distancia puede ser positiva o negativa, para hacer una ponderación de distancia deberíamos tomar su valor positivo, lo que se puede hacer tomando el valor absoluto pero lo más común es elevar esta distancia al cuadrado.

$$d^2 = (y_{\text{true}_i} - y_{\text{pred}_i})^2$$


$$\text{loss} = \sum (y_{\text{true}_i} - y_{\text{pred}_i})^2$$

La mejor recta será entonces la que menor **loss** tenga. También es conocido como RSS (Residual Sum of Squares).

Generalizando

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

$$RSS = \sum_{i=1}^n y_i - \beta_0 - \beta_1 x_i$$

Minimizo error cuando las derivadas parciales son iguales a cero.

$$\delta RSS / \delta \beta_0 = \sum_{i=1}^n -2(y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\sum_{i=1}^n y_i - \sum_{i=1}^n \beta_0 - \sum_{i=1}^n \beta_1 x_i = 0$$

$$\sum_{i=1}^n y_i - n\beta_0 - \sum_{i=1}^n \beta_1 x_i = 0$$

$$n\beta_0 = \sum_{i=1}^n y_i - \sum_{i=1}^n \beta_1 x_i$$

$$\beta_0 = 1/n \sum_{i=1}^n y_i - 1/n \sum_{i=1}^n \beta_1 x_i$$

$$\beta_0 = 1/n \sum_{i=1}^n y_i - 1/n \sum_{i=1}^n \beta_1 x_i$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

$$\delta RSS / \delta \beta_1 = \sum_{i=1}^n -2x_i(y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\sum_{i=1}^n x_i(y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\sum_{i=1}^n x_i(y_i - \bar{y} + \beta_1 \bar{x} - \beta_1 x_i) = 0$$

$$\sum_{i=1}^n x_i(y_i - \bar{y}) - \beta_1 x_i(x_i - \bar{x}) = 0$$

$$\sum_{i=1}^n x_i(y_i - \bar{y}) - \beta_1 x_i(x_i - \bar{x}) = 0$$

$$\sum_{i=1}^n x_i(y_i - \bar{y}) = \beta_1 \sum_{i=1}^n x_i(x_i - \bar{x})$$

$$\beta_1 = \sum_{i=1}^n x_i(y_i - \bar{y}) / \sum_{i=1}^n x_i(x_i - \bar{x})$$

$$\beta_1 = \frac{\sum_{i=1}^n \underbrace{(x_i - \bar{x})}_{\substack{\text{desviación de } x_i \\ \text{respecto a la media de } x}} \underbrace{(y_i - \bar{y})}_{\substack{\text{desviación de } y_i \\ \text{respecto a la media de } y}}}{\sum_{i=1}^n \underbrace{(x_i - \bar{x})^2}_{\substack{\text{variabilidad de } X \\ \text{respecto a su media}}}}$$


¿Qué representa?

β_1 es la **pendiente** de la recta de regresión que mejor ajusta los datos (mínimos cuadrados).

Indica **cuánto cambia Y, en promedio, cuando X cambia en una unidad.**

Es decir: $\Delta Y / \Delta X$ (ajustado linealmente).

Interpretación geométrica



Matricialmente

$$RSS = (Y - XB)^T(Y - XB)$$

$$\delta RSS / \delta B = -2X^t(Y - XB) = 0$$

$$X^t(Y - XB) = 0$$

$$X^tY = X^tXB$$

$$B = (X^tX)^{-1}X^tY$$

$$B = \underbrace{\begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix}}_{\substack{\text{Vector de} \\ \text{parámetros} \\ (p+1) \times 1}} = \underbrace{\begin{bmatrix} c_{00} & c_{01} & \cdots & c_{0p} \\ c_{10} & c_{11} & \cdots & c_{1p} \\ \vdots & \vdots & \ddots & \vdots \\ c_{p0} & c_{p1} & \cdots & c_{pp} \end{bmatrix}}_{\substack{\text{Matriz inversa} \\ (p+1) \times (p+1)}} \times \underbrace{\begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_{11} & x_{21} & \cdots & x_{n1} \\ x_{12} & x_{22} & \cdots & x_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1p} & x_{2p} & \cdots & x_{np} \end{bmatrix}}_{\substack{\text{Traspuesta de } X \\ (p+1) \times n}} \times \underbrace{\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{bmatrix}}_{\substack{\text{Vector de} \\ \text{observaciones} \\ n \times 1}}$$

$B = (X^T X)^{-1} X^T Y$

La primera columna de X generalmente se llena con unos para tener en cuenta la intersección.



Data

```
x = np.array([1, 2, 3, 4, 5])
```

```
y = np.array([2, 3, 4, 2, 6])
```

scikit-learn

```
model = LinearRegression()
```

```
model.fit(x, y)
```

```
pendiente = model.coef_[0]
```

```
intercepto = model.intercept_
```

```
pendiente, intercepto
```

```
(0.7000000000000002, 1.2999999999999994)
```

numpy

```
y_mean = y.mean()
```

```
x_mean = x.mean()
```

```
beta_1 = np.sum(x.T*(y-y_mean))/np.sum(x.T*(x.T-  
x_mean))
```

```
beta_0 = y_mean - beta_1 * x_mean
```

```
beta_1 , beta_0
```

```
(0.7000000000000001, 1.2999999999999998)
```



Métricas

$$\text{MSE} = \text{RSS} / n$$

$$\text{RMSE (root mean squared error)} = \sqrt{\text{MSE}}$$

$$\text{MAE (mean absolute error)} =$$

$$\frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$\text{MAPE (mean absolute percentage error)} \quad \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$


Métricas

Así como se habló de RSS (residual sum of squares) se puede hablar de TSS: total sum of squares.

Mide la variabilidad total de los valores reales respecto de su media (la suma de los cuadrados de las diferencias entre los valores reales y la media de los valores reales).

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2$$

TSS representa el error que tendríamos si, en lugar de utilizar un modelo, predijéramos siempre la media.



Métricas

¿Qué tan lejos están los valores reales de lo que predice nuestro modelo?


- Variabilidad que no puede explicarse por la regresión lineal.

$$RSS = \sum_{i=1}^n y_i - \beta_0 - \beta_1 x_i$$

¿Qué tan lejos están los valores reales de simplemente utilizar la media como predicción?

- Variabilidad de los Datos

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2$$





Métricas

$$R^2 = 1 - \frac{RSS}{TSS}$$

TSS mide variabilidad de los datos, RSS la variabilidad que no puede explicarse por la regresión lineal. De tal forma que su resta mide la variabilidad que sí es explicada por la regresión lineal.

Mientras más bajo es la suma residuales de cuadrados respecto a la variación total de los datos respecto de su media, más cerca de 1, y se puede decir que la regresión lineal explica de buena forma la variabilidad de los datos.

Si es cercano a cero, implica que RSS es considerable respecto de TSS.

Si es cero, implica $RSS = TSS$. La suma de los cuadrados del desvío de cada dato con la predicción es lo mismo que el desvío de cada dato con su media -> el modelo es tan simple como el promedio de los datos.

¿Puede ser menor a cero?

Correlación



Features muy correlacionadas linealmente

$$y = a x_1 + b x_2 + c$$

$$\text{Si } x_2 = d x_1$$

$$y = a x_1 + b d x_1 + c$$

$$y = (a + bd) x_1 + c$$



Coeficiente de correlación de Pearson

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Coeficiente de correlación de Pearson

