



Regresión Lineal

Aprendizaje Automático 1

Regularización




Métodos de ajuste

Se busca mejorar el modelo de regresión lineal múltiple

- Selección de características: análisis de colinealidad y correlación
- Regularización
- Reducción de dimensionalidad



puede que con sólo algunas componentes se explique un gran porcentaje de la respuesta (por lo general se busca arriba del 90%). Es un método no supervisado.



buscar patrones, matriz de correlación de Pearson, o simplemente probar todas las combinaciones posibles hasta encontrar la de mejores métricas



Regularización

Como una alternativa a elegir los predictores manualmente, se puede dar un enfoque más restrictivo a la hora de utilizar los mínimos cuadrados.


Los métodos de regularización achican los coeficientes menos significativos para reducir la varianza y así intentar aproximar a un mejor modelo.

Existen muchas técnicas, pero las más conocidas son Ridge y Lasso.




OLS

$$\beta_1 = 1.022, \beta_0 = -0.17$$




OLS with outlier

$$\beta_1 = 5.402, \beta_0 = -13.15$$



L2 Ridge with outlier

$$\beta_1 = 1.369, \beta_0 = 7.02$$





Regularización

$$\text{RSS} = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2.$$

$$\underset{\beta}{\text{minimize}} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \right\} \quad \text{subject to} \quad \sum_{j=1}^p I(\beta_j \neq 0) \leq s.$$



Regresión Ridge

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 = \text{RSS} + \lambda \sum_{j=1}^p \beta_j^2$$

es equivalente al problema de la diapositiva anterior, y puede demostrarse con multiplicadores de Lagrange (escapa el alcance de la materia)



Regresión Ridge

El segundo término es una penalidad a los coeficientes y busca minimizar el cuadrado de su suma.

Si $\lambda=0$ es una regresión lineal común

Si $\lambda \rightarrow \infty$ ya no importa tanto los RSS sino que todos los coeficientes sean bajos.

Es clave la elección de λ . Por lo general se hace con **Validación Cruzada**.

λ no se aplica a la intersección con el eje y (β_0).



Regresión Ridge

Funciona mejor en situaciones donde los valores estimados tienen mucha varianza

(si las variables tienen una relación lineal importante, RSS tiende a tener varianza ya que un mínimo cambio en los datos produce un cambio importante en la pendiente de la recta)



Regresión Ridge

Tiene una desventaja, que es que usa **todos los predictores**.

Es decir, no va a lograr que ningún B sea cero (algo que sí sucede cuando elegimos nosotros las variables a usar!)



Regresión Lasso

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j| = \text{RSS} + \lambda \sum_{j=1}^p |\beta_j|$$




Regresión Lasso




Un λ suficientemente grande puede acarrear que algunos coeficientes se anulen para disminuir el error.

Lo cual puede ser muy útil para hacer una selección de features “automática”.

Ridge vs Lasso



A medida que sube el exponente, la figura va tendiendo de un círculo a un cuadrado.



Las áreas celestes son las áreas de restricción $|\beta_1| + |\beta_2| \leq s$ y $\beta_1^2 + \beta_2^2 \leq s$, y las elipses rojas son contornos del RSS (lugares donde el RSS vale lo mismo). $\hat{\beta}$ es el beta óptimo (el que menor RSS da para los datos).



Ridge vs Lasso

Ridge tiene una restricción circular sin puntos “afilados”, la intersección generalmente no ocurre en un eje -> Ridge no anula el valor de las componentes pero sí los **armoniza**.

La restricción de Lasso tiene esquinas en cada uno de los ejes, por lo que la elipse a menudo intersecta la región de restricción en un eje y por lo tanto **anula** componentes.

En dimensiones superiores, muchas de las estimaciones de coeficientes pueden ser igual a cero simultáneamente. En la figura anterior, la intersección ocurre en $\beta_1 = 0$, por lo que el modelo resultante sólo incluirá β_2 .



ElasticNet

Usa ambas restricciones, dadas por un $l1_ratio$, que indica cuánto es la componente de Lasso. Por lo tanto usa un $1-l1_ratio$ de Ridge

Minimiza:

$$\begin{aligned} & 1 / (2 * n_samples) * ||y - Xw||^2_2 \\ & + \alpha * l1_ratio * ||w||_1 \\ & + 0.5 * \alpha * (1 - l1_ratio) * ||w||^2_2 \end{aligned}$$



Escalado de datos

¿Creen que la data debería estar **escalada** antes de usar regularización?