



Análisis exploratorio, valores atípicos y faltantes

Aprendizaje Automático 1

Análisis exploratorio

Los datos crudos que nos llegan generalmente están sin procesar o con ruido de fondo, donde podemos encontrar:

- Campos redundantes
- Formatos que no nos sirven para el análisis
- Valores que no pasan por pruebas lógicas de consistencia

Siendo esencial analizar previamente los sets de datos.



Análisis exploratorio

El Análisis Exploratorio de Datos (AED) es un enfoque de análisis de datos que implica examinar, resumir y visualizar conjuntos de datos para comprender sus características fundamentales.

- Permite familiarizarse con la naturaleza y la estructura de los datos antes de realizar cualquier análisis avanzado.
- Al explorar los datos de manera exhaustiva, es posible identificar problemas como valores atípicos, errores de entrada o datos faltantes.
- Permite descubrir patrones ocultos, tendencias y relaciones entre las variables.
- Permite validar las suposiciones iniciales sobre los datos.






Valores faltantes

- Eliminación de datos faltantes: implica eliminar filas o columnas que contienen valores faltantes, puede ser apropiado si los valores faltantes son solo una pequeña proporción del conjunto de datos y si la eliminación no introduce sesgos significativos en los análisis posteriores.
- Imputación de valores faltantes: implica estimar y completar los valores faltantes con algún tipo de valor sustituto. Algunas técnicas comunes de imputación incluyen:
 - Media, mediana o moda
 - Basada en algoritmos de predicción : se utilizan técnicas más avanzadas, como regresión, k-vecinos más cercanos (k-NN), árboles de decisión, etc., para predecir los valores faltantes en función de otros atributos del conjunto de datos.
- Métodos de interpolación: son útiles para datos secuenciales o temporales, donde los valores faltantes pueden ser estimados a partir de valores cercanos en el tiempo.
- Métodos basados en modelos: utilizar modelos predictivos para estimar los valores faltantes.

Valores atípicos

El tratamiento de outliers, o valores atípicos, es importante en el análisis de datos para garantizar que los modelos y conclusiones derivadas de ellos sean robustos y confiables.

Los outliers son observaciones que están significativamente fuera de la distribución esperada de los datos y pueden distorsionar los resultados si no se manejan adecuadamente.



Valores atípicos: *tratamiento*

- Identificación de outliers
 - Eliminación
 - Transformación de datos
 - Truncamiento
 - Imputación
 - Modelos específicos

